Réunion AMMnet, Dakar 2025

## Développer des tableaux de bord de visualisation de données en R

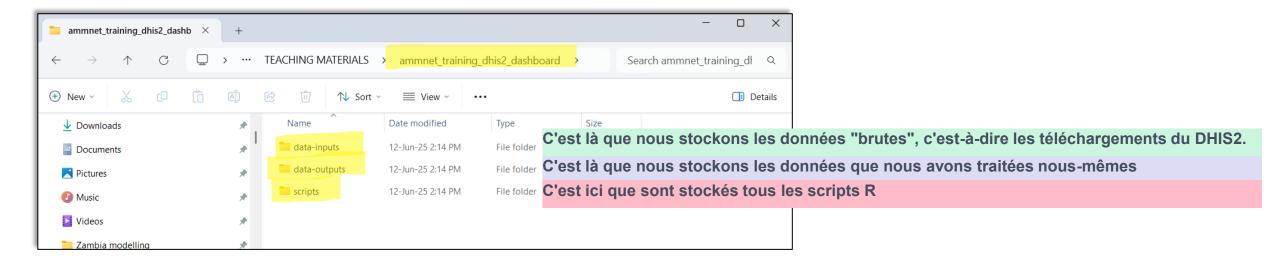
Demba Kande Sarja Jarjusey Hayley Thompson





### Préparation de la session en attendant de commencer

- 1) S'ASSURER D'AVOIR UN ACCÈS À L'INTERNET
- 2) ASSUREZ-VOUS D'AVOIR TÉLÉCHARGÉ R ET RSTUDIO
- 3) Créez un dossier dans un endroit judicieux de votre ordinateur, appelé quelque chose comme "ammnet\_training\_dhis2\_dashboard".
- 4) Dans ce dossier, créez trois sous-dossiers



5) Si vous savez comment créer un **projet** dans R, faites-le dans ce même dossier (sinon, demandez l'aide d'un animateur ou d'un voisin).



### Structure de l'atelier

Session 1 : Comment extraire manuellement des données de DHIS2 et les nettoyer pour les utiliser dans un tableau de bord ?

Session 2 : Développement d'un tableau de bord Rshiny simple pour visualiser les données de routine sur le paludisme



### Introduction au DHIS2

DHIS2 est un système d'information sur la gestion de la santé (HMIS) à code source ouvert, basé sur le web et développé par l'Université d'Oslo. Il permet la collecte, l'analyse, la visualisation et la communication des données.

Il a été adopté par les ministères de la santé de plus de 70 pays, en particulier en Afrique, en Asie et en Amérique latine. Il est couramment utilisé aux niveaux national et infranational pour la communication de données de routine sur la santé.

Les principales caractéristiques du DHIS2 sont les suivantes

Saisit les données des établissements et des programmes de santé (par exemple, paludisme, VIH, santé maternelle). Permet de créer des tableaux de bord, des cartes et des graphiques en temps réel pour la prise de décision.

Favorise la saisie intégrée et décentralisée des données dans l'ensemble du système de santé

Facilite le suivi, l'évaluation et la planification grâce à des analyses personnalisées



### Plan de la session 1

- Comment accéder au DHIS2
- Explorer quelques tableaux de bord existants pour voir les fonctionnalités graphiques
- Apprendre à faire une requête de données pour accéder aux éléments de données, à la période de temps et aux unités géographiques qui nous intéressent.
- Télécharger les données au format csv
- Lecture des données dans R
- Nettoyer les données, y compris le nettoyage des noms, l'inspection visuelle des données aberrantes/manquantes, le recoupement de différentes variables.

Le résultat de cette session est un ensemble de données nettoyées sur le paludisme que nous utiliserons pour la deuxième partie (construction d'un tableau de bord brillant).



## Naviguer dans DHIS2

DHIS2 dispose d'une base de données de démonstration basée sur la RDP Lao mais contenant des données inventées.

Voici ce que nous utiliserons dans l'atelier d'aujourd'hui



DHIS 2

**English** 

Username : demo\_en Password : District1#

French

Username : demo\_fr Password : District1#

Spanish

Username : demo\_es Password : District1#

Portuguese

Username : demo\_pt Password : District1#

Arabic

Username : demo\_ar Password : District1#

Russian

Username : demo\_ru Password : District1#

Access the aggregate forms by using the "Data Entry" app and tracker programs in the "Tracker Capture" app.



Sign in

Username

Password

Sign in

Disclaimer: This database is for demonstration purposes only. The demo database does NOT reflect real country data from Lao PDR. HISP Centre extends its appreciation to the Lao PDR Ministry of Health for partnering on the development of a DHIS2 demo environment.

Powered by DHIS 2

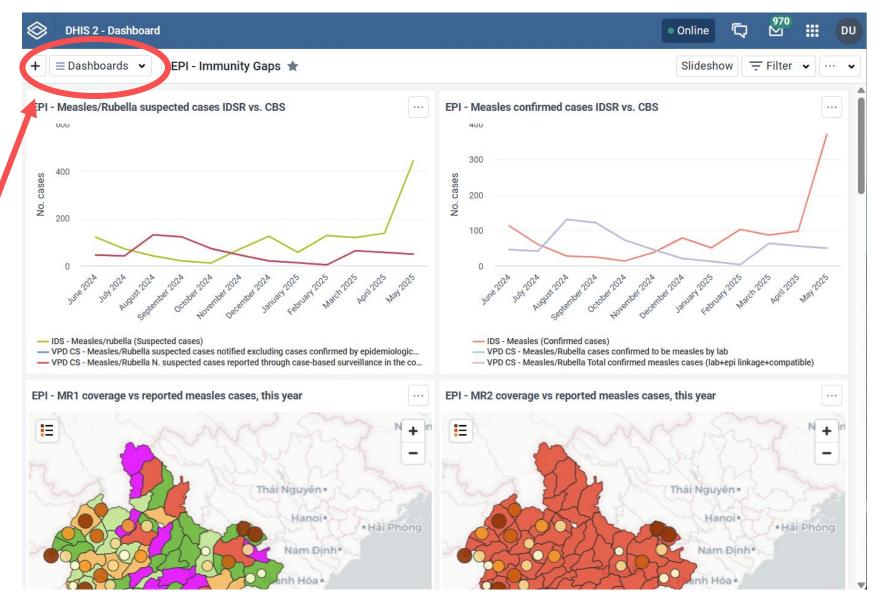
[ Change language ]



## Tableaux de bord existants

Lorsque vous ouvrez cette instance de DHIS2 pour la première fois, vous verrez des tableaux de bord prédéfinis sur les maladies évitables par la vaccination et les taux de couverture vaccinale.

Vous pouvez explorer d'autres tableaux de bord prédéfinis pour voir ce qui est possible dans DHIS2.

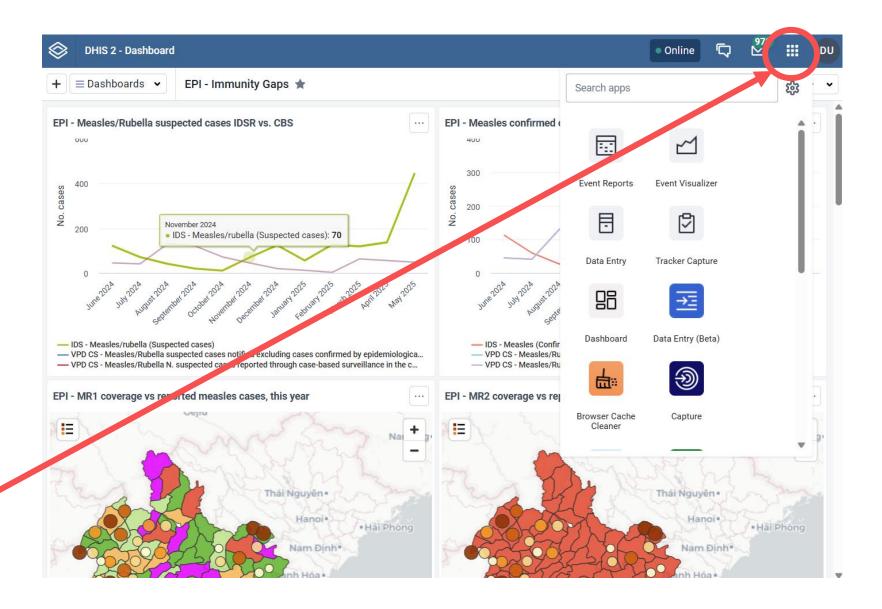




# Accès aux données brutes

DHIS2 offre de nombreuses possibilités de visualisation, mais nous souhaitons souvent extraire des données de DHIS2 pour effectuer nos propres analyses - par exemple, une stratification des risques ou un modèle statistique examinant l'impact d'une intervention.

Pour accéder aux données brutes, vous devez cliquer sur cette grille 3x3

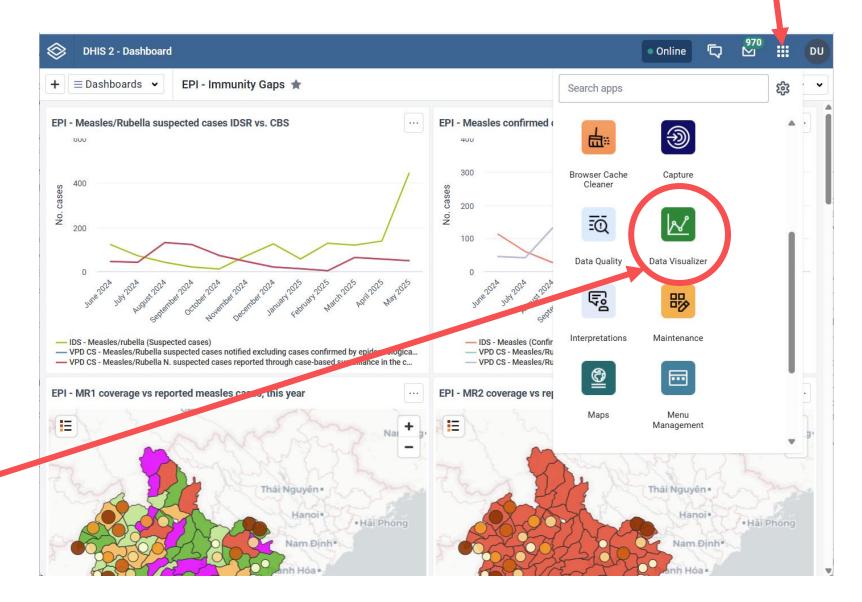




# Trouver un visualisateur de données

DHIS2 offre de nombreuses possibilités de visualisation, mais nous souhaitons souvent extraire des données de DHIS2 pour effectuer nos propres analyses - par exemple, une stratification des risques ou un modèle statistique examinant l'impact d'une intervention.

Faites défiler le menu et sélectionnez "data visualizer".





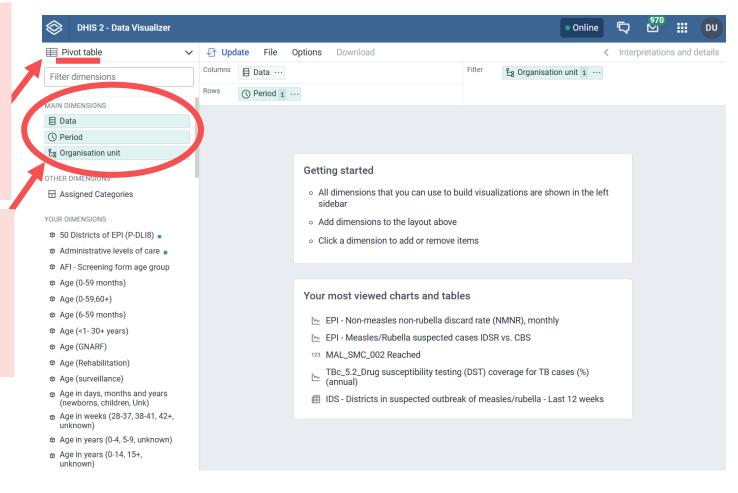
## Naviguer dans le visualiseur de données

Vous devriez maintenant voir cet écran - il y a plusieurs éléments importants sur cette page

Pour extraire les données brutes, nous voulons utiliser le **tableau croisé dynamique**, mais il existe des options permettant de présenter les données sous différents formats graphiques

C'est ici que vous **sélectionnez les données**, la période et l'unité d'organisation (c'està-dire l'établissement de santé, le service, le district, etc.

Nous allons maintenant les examiner un par un sur les diapositives suivantes





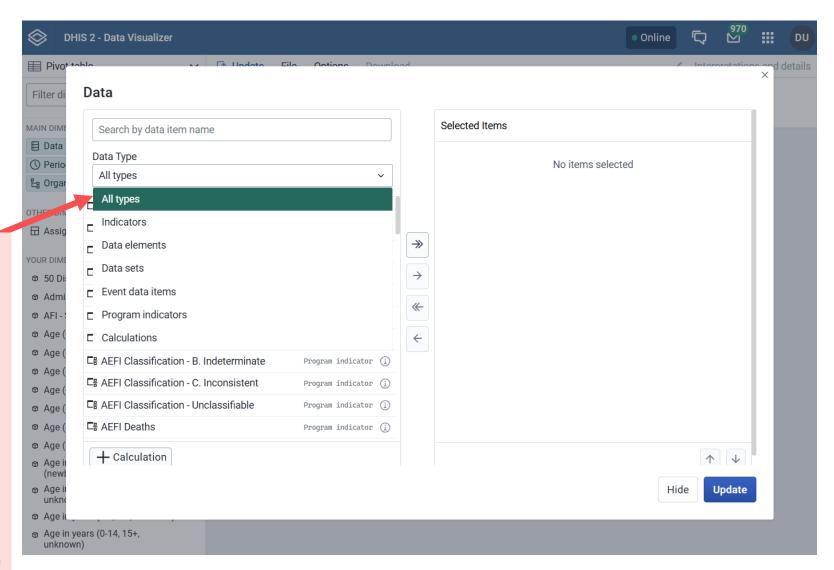
## Dimension des données

Cliquez sur l'option "données" pour afficher ce menu.

Vous pouvez voir ici qu'il existe une série de "types de données

Aujourd'hui, nous nous concentrerons sur

- Éléments de données il s'agit des éléments constitutifs des données dans le DHIS2 - il s'agit généralement d'un "décompte", c'est-à-dire des cas de paludisme ou des TDR effectués.
- Indicateurs ils sont calculés sur la base d'une combinaison d'éléments de données, par exemple : nombre de tests effectués = nombre de TDR + nombre de microscopies, incidence = cas/population.





## Trouver des données sur le paludisme (1)

Évitez les indicateurs de paludisme précédés du préfixe "CH" - ils concernent les cas détectés par la gestion communautaire des cas - nous nous concentrerons aujourd'hui sur les cas de paludisme signalés dans les établissements de santé.

Premièrement, sélectionner les **éléments de données** 

Sélectionnez ensuite la réduction de la charge de morbidité du paludisme dans le champ de l'élément de données.

Nous voyons ici un large éventail de variables relatives à la charge de morbidité du paludisme

Search by data item name Data Type Data elements Data element group Disaggregation Malaria burden reduction Totals only GEN - All-cause inpatients Data element (i) · GEN - All-cause outpatients Data element (i) o GEN - Population expected pregnant women Data element (i) MAL - ACT issued Data element (i) MAL - ACTs courses received by patients Data element (i) o MAL - All-cause death Data element (i) MAL - Confirmed cases (pregnant women) Data element (i) MAL - Confirmed cases treated with ACT Data element (i) MAL - Confirmed malaria cases Data element (i) + Calculation

Selected Items No items selected Hide

Pour l'exemple d'aujourd'hui, nous examinerons les cas confirmés de paludisme et les tests de paludisme (TDR et microscopie) effectués.

Pour sélectionner une variable, mettez-la en surbrillance comme indiqué ici, puis appuyez sur la flèche "en travers" du haut pour la déplacer dans la section des éléments sélectionnés.



## Trouver des données sur le paludisme (2)

#### $\times$ Data Selected Items Search by data item name o MAL - Confirmed malaria cases Data element (i) Data Type o MAL - Malaria suspects tested (RDT) Data element (i) Data elements • MAL - Malaria suspects tested with microscopy Data elemer (i) Data element group Disaggregation o MAL - Microscopy positive malaria cases Data element (i) Totals only Malaria burden reduction o MAL - RDT positive malaria cases Data element (i) • MAL - Plasmodium vivax (RDT) Data element (i) MAL - Plasmodium vivax (microscopy) Data element (i) o MAL - Population at risk for malaria Data element (i) • MAL - Population with malaria age disaggregation Data element (i) • MAL - Presumed cases (pregnant women) Data element (i) o MAL - Presumed malaria cases Data element (i) • MAL - RDT positive malaria cases (pregnant women) Data element (i) • MAL - Suspected malaria cases Data element (i) • MAL - Suspected malaria cases (pregnant women) Data element (i) + Calculation

Sélectionnez ces 5 éléments de données sur le paludisme



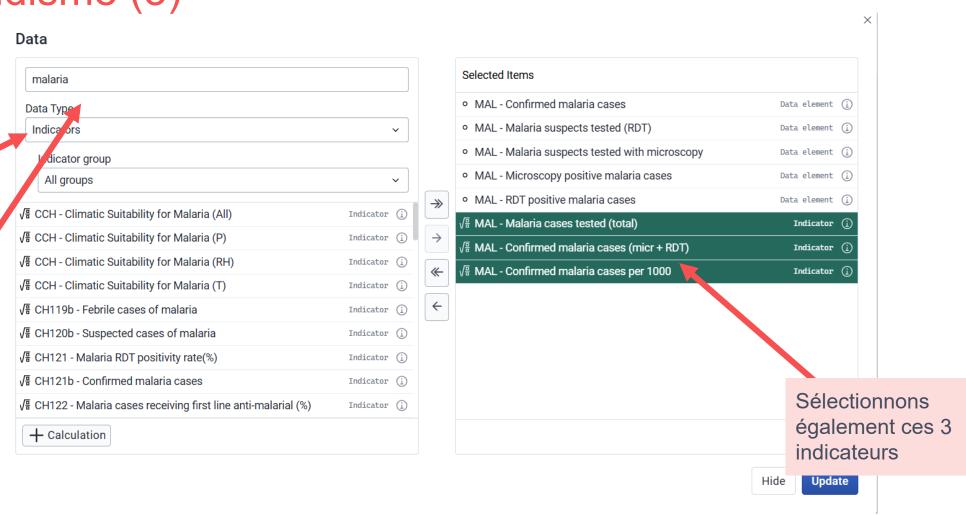
Hide

Update

## Trouver des données sur le paludisme (3)

Nous utiliserons également certains indicateurs de paludisme

Une autre façon de trouver vos indicateurs est de taper un motclé dans le champ supérieur.



## Une remarque sur la recherche des "bonnes" variables

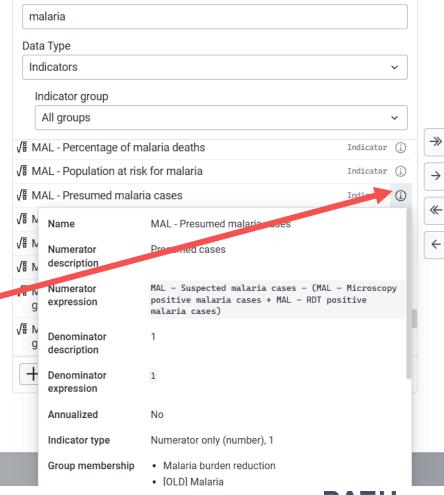
Il existe généralement un grand nombre de variables liées à la charge de morbidité du paludisme, et tous les pays ne communiquent pas régulièrement toutes les variables. Nous commençons généralement par demander à un expert local quels sont les éléments/indicateurs à utiliser.

À défaut, nous pouvons interroger manuellement les données pour voir lesquelles sont signalées

N'hésitez pas à sélectionner un éventail beaucoup plus large de variables relatives au paludisme afin de déterminer si elles sont toutes utiles et comment elles sont liées les unes aux autres.

Il y a aussi parfois des variables en double, par exemple, cette démo DHIS2 a 2 indicateurs identiques pour le nombre total de cas de paludisme. Vous pouvez cliquer sur le "i" encerclé Cliquez ici pour obtenir plus de détails sur chaque variable

#### Data



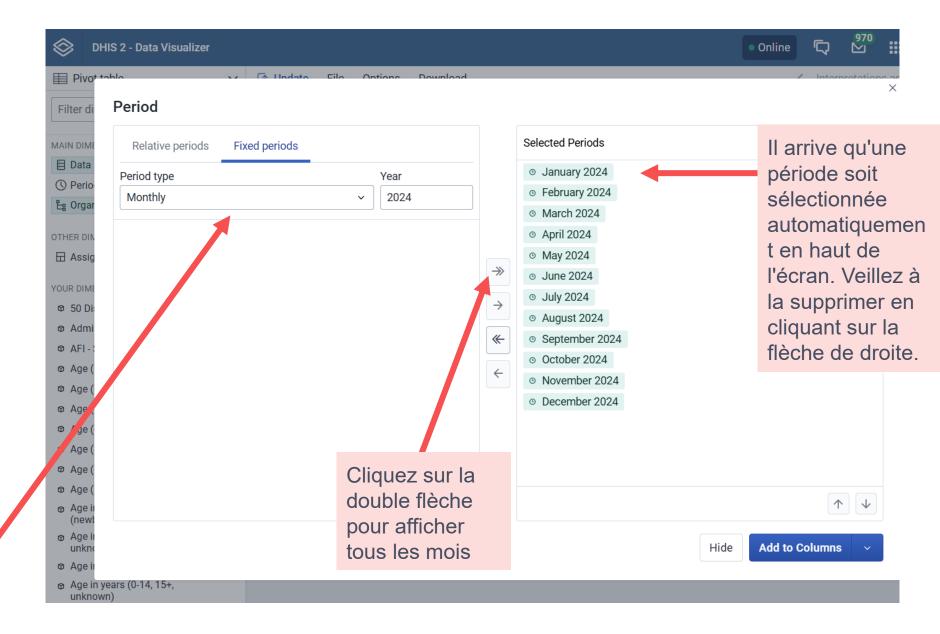


# Sélection des périodes de temps

Vous pouvez sélectionner une période relative à aujourd'hui (c'est-à-dire les trois derniers mois) ou des périodes fixes.

Dans cet exemple, nous allons examiner les données mensuelles de 2024 seulement

Sélectionnez d'abord "périodes fixes", puis "mensuel" et "2024".



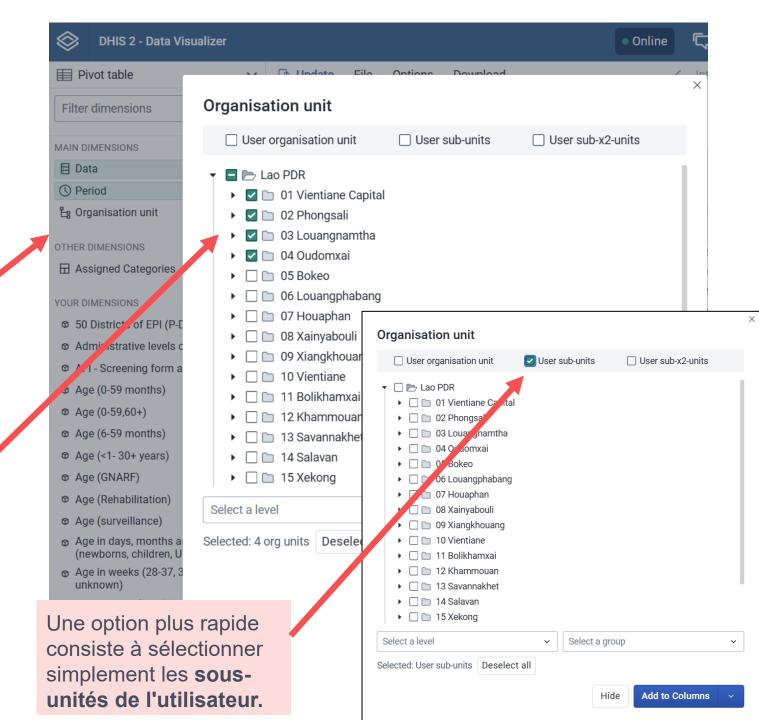


## Sélection de l'unité d'organisation

Pour l'instant, nous examinons les totaux nationaux, mais nous pouvons également étudier les données au niveau d'unités spatiales plus petites - jusqu'au niveau de l'établissement de santé.

## Sélectionner l'unité d'organisation

Nous pouvons soit sélectionner toutes les provinces manuellement en cochant les cases - cette méthode est préférable lorsque nous voulons seulement examiner un sous-ensemble de provinces, de districts, etc.



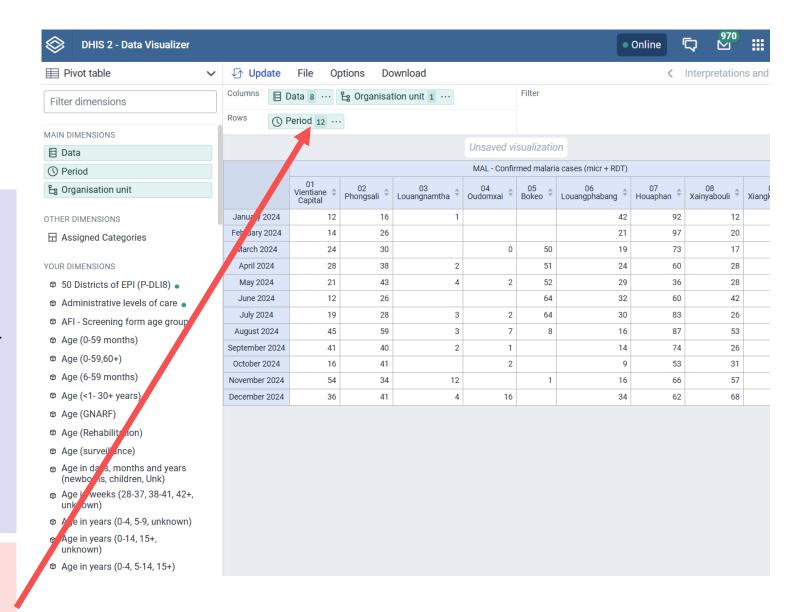
## Réorientation et téléchargement des données (1)

Les données sont renvoyées dans un format large, avec 18 colonnes (une par province) pour chaque indicateur

Pour les futures manipulations de données dans R, il est préférable d'avoir les données dans un **format long** 

Il s'agit d'un format de données dans lequel chaque ligne représente une observation unique et chaque colonne représente une variable ou une caractéristique.

Pour obtenir des données en format long, nous pouvons faire glisser ces cases vertes vers la zone des lignes (voir diapositive suivante).

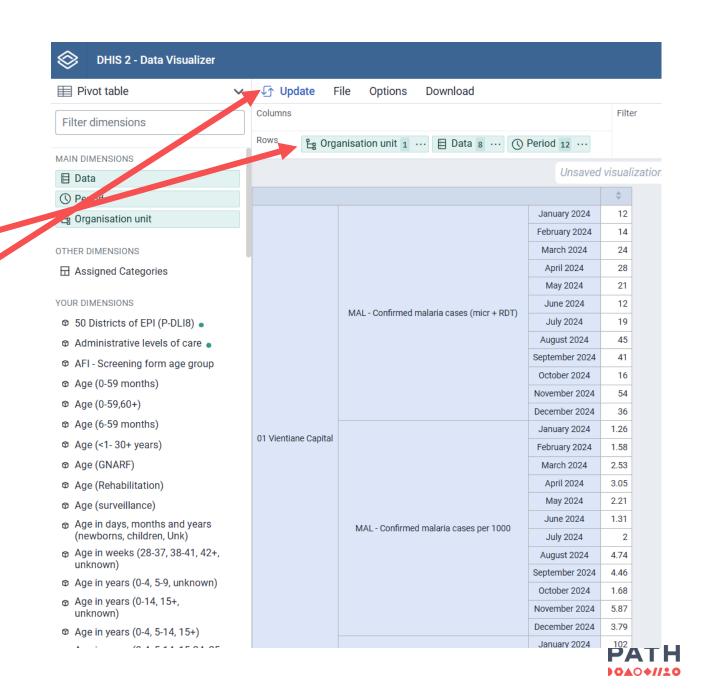


Ressources utiles pour en savoir plus sur les données **longues** et les données **larges** <a href="https://tavareshugo.github.io/r-intro-tidyverse-gapminder/09-reshaping/index.html">https://tavareshugo.github.io/r-intro-tidyverse-gapminder/09-reshaping/index.html</a>

## Réorientation et téléchargement des données (2)

Vous pouvez modifier l'ordre de ces éléments pour déterminer ce qui est le plus logique pour vos données.

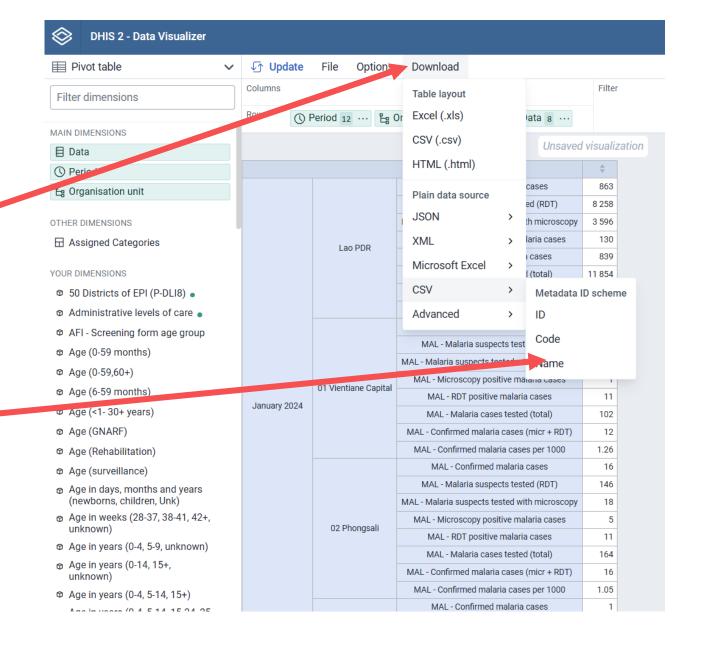
Vous devrez mettre à jour le tableau chaque fois que vous le modifiez



## Réorientation et téléchargement des données (3)

Nous pouvons maintenant **télécharger** nos données au format csv

Le format de données le plus facile à utiliser est source de données simples -> CSV -> Nom.

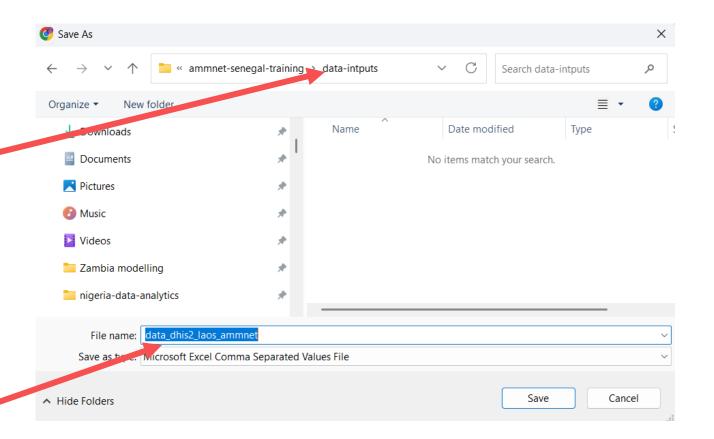




## Réorientation et téléchargement des données (4)

Enregistrez vos données dans le dossier "datainputs" que vous avez créé au début de la session.

Renommez votre fichier en quelque chose d'informatif - j'ai choisi data\_dhis2\_laos\_ammnet





### Lecture des données dans R et nettoyage

Pour cette section, nous avons juste besoin de 2 paquets tidyverse et janitor, si vous ne les avez pas déjà, vous pouvez les installer avec les commandes

```
install.packages("tidyverse")
install.packages("janitor")
Étape 1 : lire les données, nettoyer les noms et examiner les données
library(tidyverse)
library(janitor)
laos dat <- read csv("data-inputs/data dhis2 laos ammnet.csv") %>%
     clean names()
head(laos dat)
```



### Nettoyage (1)

Ces noms de données semblent longs et encombrants - raccourcissons-les une fois que nous avons décidé lesquels utiliser Le téléchargement a renvoyé les données au niveau national, ce que nous ne voulons pas - filtronsles.

Ces colonnes n'ont pas l'air utiles, nous allons donc les supprimer de notre résultat.

```
# A tibble: 6 \times 9
                        period organisation_unit value humerator denominator factor multiplier divisor
  data
                                                                  <db1>
                                                                                <db1> <db1>
                                                                                                      \langle db 1 \rangle
  <chr>
                         <chr> <chr>
                                                      \langle db 1 \rangle
                                                                                                               \langle db1 \rangle
1 MAL - Malaria cas... Janua... Lao PDR
                                                      11854
                                                                  11854
2 MAL - Malaria cas... Janua... 01 Vientiane Cap...
                                                        102
                                                                    102
3 MAL - Malaria cas... Janua... 02 Phongsali
                                                        164
                                                                    164
4 MAL - Malaria cas... Janua... 43 Louangnamtha
                                                        122
                                                                    122
5 MAL - Malaria cas... Janua... 04 Oudomxai
                                                        169
                                                                    169
                                                                                             1
6 MAL - Malaria cas... Janua... 05 Bokeo
                                                         80
                                                                     80
```

La date est au format caractère, mais nous avons besoin qu'elle soit au format date pour que R sache comment elle doit être ordonnée

### Nettoyage (2)

Il est conseillé d'examiner les valeurs uniques de chaque colonne de texte pour vérifier qu'elles ont toutes un sens.

```
unique(laos_dat$data)
[1] "MAL - Cas de paludisme testés (total)" "MAL - Cas de paludisme confirmés (micr + RDT)"
[3] "MAL - Cas de paludisme confirmés pour 1000" "MAL - Cas de paludisme confirmés"
[5] "MAL - Cas de paludisme positifs à la microscopie" "MAL - Suspects de paludisme testés (TDR)"
[7] "MAL - Cas suspects de paludisme testés par microscopie" "MAL - Cas de paludisme positifs au TDR"
```

Nous avons téléchargé des données portant des noms similaires pour en vérifier la cohérence - vérifions-les maintenant - je m'attends à ce que

```
MAL - Cas de paludisme testés (total)" = "MAL - Cas suspects de paludisme testés (TDR)" + "MAL - Cas suspects de paludisme testés par microscopie".

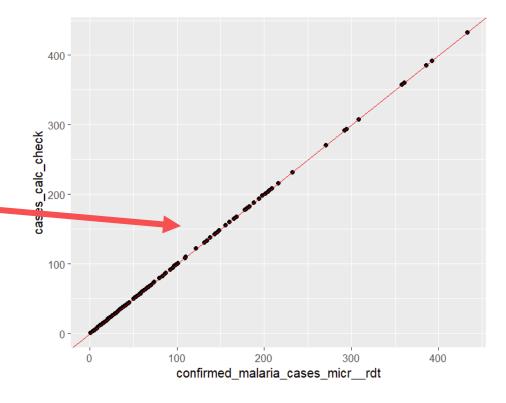
Et

"MAL - Cas de paludisme confirmés (micr + RDT)" = "MAL - Cas de paludisme positifs à la microscopie" + "MAL - Cas de paludisme positifs au RDT" =
```



### Nettoyage (3)

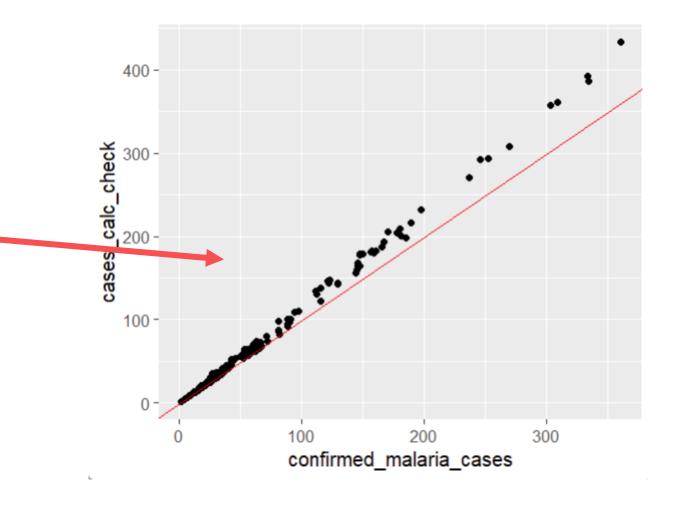
```
laos_dat_wide <- laos_dat_clean %>%
    pivot wider(names from = data) %>%
    mutate(test_calc_check = rowSums(across(c(malaria_suspects_tested_rdt,
malaria_suspects_tested_with_microscopy)), na.rm = TRUE), cases_calc_check
= rowSums(across(c(rdt positive malaria cases,
microscopy positive malaria cases))))
ggplot(laos dat wide) +
    geom_point(aes(x = malaria_cases_tested_total,
                    y = test calc check)) +
    geom abline(intercept = 0, slope = 1, color = "red")
                   Nous voyons ici que ces deux variables
                   sont cohérentes, nous pouvons donc
                   continuer à n'en considérer qu'une
                   seule
```



## Nettoyage (4)

Il n'en va pas de même lorsque nous comparons les **cas\_calc\_check** avec les cas de **paludisme confirmés** (nous nous attendons à ce que les points se situent sur la ligne rouge (x=y)).

Q : Pouvez-vous écrire le code permettant de générer ce graphique ?



Cela signifie que nous, en tant qu'analystes de données, devons **prendre une décision** sur la variable à utiliser.

Option 1 : demander à un expert local

Option 2 : prendre une **décision éclairée** et **documenter** cette décision afin de pouvoir expliquer vos résultats de manière transparente à l'avenir.

Pour cette analyse, nous utiliserons les cas de paludisme confirmés (car nous avons parlé à un responsable de la surveillance au Laos qui a indiqué que dans certains contextes, les personnes sont testées à la fois par TDR et par microscopie, ce qui peut conduire à un double comptage des cas).

### Nettoyage (5)

Filtrer uniquement les variables que nous voulons pour notre tableau de bord

données == "cas de paludisme confirmés" ~ "cas de paludisme",

data == "confirmed malaria cases per 1000" ~ "malaria cases per 1000")) %>%

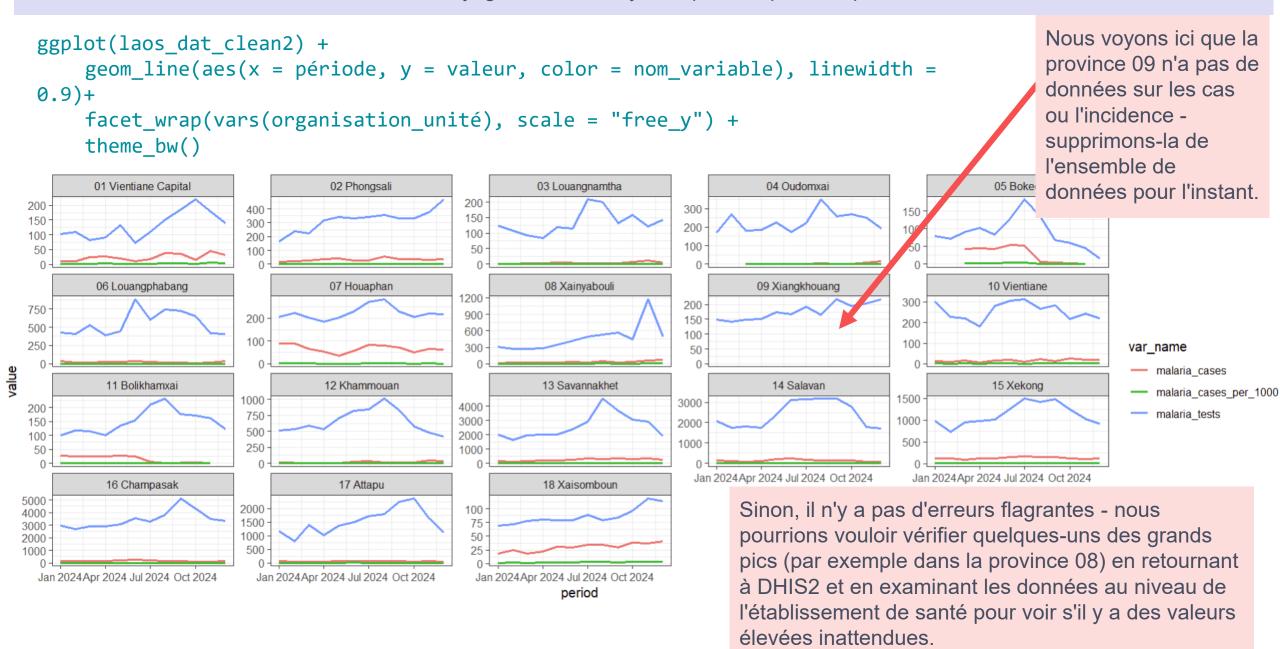
dplyr::select(organisation\_unit, period, var\_name, value) %>%
arrange(organisation unité, période)

Renommez-les pour qu'ils soient plus courts et plus faciles à utiliser

> Sélectionner uniquement la colonne que l'on souhaite utiliser et la classer dans un ordre plus logique



Tracez **TOUJOURS** vos données lors du nettoyage - c'est le moyen le plus simple de repérer les anomalies/erreurs.



Filtrer la province avec des variables manquantes

laos\_dat\_final <- laos\_dat\_clean2 %>% filter(organisation\_unit != "09 Xiangkhouang")

write\_csv(laos\_dat\_final, "data-outputs/data\_dhis2\_laos\_ammnet\_cleaned.csv")



Enregistrez votre résultat dans le dossier dataoutputs, en notant qu'il s'agit maintenant d'un jeu de données nettoyé.

Si vous n'avez pas encore réussi à télécharger et à nettoyer les données, téléchargez cet ensemble de données afin d'être prêt pour la deuxième partie : la construction d'un tableau de bord brillant.